OSTBAYERISCHE
TECHNISCHE HOCHSCHULE
REGENSBURG

Studie zur verbesserten Anomalyerkennung mit erweiterter Kontextinformation

Research work
of

Yannic Hanel
3296954

curriculum
at the

Ostbayerischen Technischen Hochschule Regensburg
Faculty of Computer Science and Mathematics

Advisor: Prof. Dr. Sebastian Fischer

Regensburg, 20.02.2026

Contents

Abkürzungsverzeichnis **4**

1 Einleitung **1**
1.1 Motivation und Problemstellung 1
1.2 Zielsetzung der Arbeit 1
1.3 Aufbau der Arbeit 1

2 Related Work **3**

3 Systemarchitektur und Detection Framework **4**
3.1 Systemüberblick und verteilte Kommunikation 4
3.1.1 Privates IPFS-Netzwerk und Peer-to-Peer-Datenaustausch 5
3.1.2 End-to-End-Datenfluss 5
3.2 Physische Testumgebung 8
3.3 Detection Units der Ladeinfrastruktur 8
3.3.1 System- und Leistungsanomaliedetektion (pi_anomaly_detection) 8
3.3.2 Physikalische Signal- und Temperaturüberwachung (detection_power_temperature) 8
3.3.3 KI-basierte Angriffserkennung im Netzwerk (ids_power_ai_detection) . . 8
3.3.4 Hardware-Ereignisüberwachung (detection_hardwareevents) 8

4 Konzeption des Threat Reporters **9**
4.1 Standardisierung durch den Threat Report (CSV/STIX) 9
4.2 Zeitfenster-Analyse und Datenaggregation (60s/30s Intervalle) 9
4.3 Schnittstellendesign für den Datentransfer zwischen Nodes 9

5 Theoretische Grundlagen der Informationsfusion **10**
5.1 Vergleich von Aggregationsmethoden 10
5.1.1 Dempster-Shafer-Evidenztheorie 10
5.1.2 Fuzzy-basierte Fusion 10
5.1.3 Bayes-basierte Konsensmodelle 10
5.1.4 Gewichtetes Voting 10
5.2 State-of-the-Art: Deep Sets und Attention Mechanismen 10

6 Methodik: Gewichtete Aggregation mittels Utility Theory **11**
6.1 Anforderungen an die Gewichtungsfunktion 11
6.2 Mathematische Modellierung 11
6.2.1 Die Gewichtungsformel: $w(n) = BASE_WEIGHT + (MAX_WEIGHT - BASE_WEIGHT) \times (1 - \exp(-K \cdot n))$ 11
6.2.2 Parameteranalyse: Monotonie und Diminishing Returns 11
6.2.3 Abgrenzung zur originären Utility Theory 11
6.3 Implementierung des Attention-basierten Selektionsmodells 11

7 Erweiterung der Systemarchitektur und Implementierung **12**
7.1 Generierte Threat Reports: Format und Struktur 12

7.2 Integration von Threat Reporter und Aggregationslogik 12
7.3 Architektur der Fusionskomponente im P2P-Netzwerk 12

8 Evaluation **13**
8.1 Qualität der aggregierten Threat Reports 13
8.2 Nützlichkeit für die interne Nutzung der Knoten 13

9 Diskussion und Forschungslücken **14**
9.1 Auswirkungen unterschiedlicher Gewichtungsstrategien auf die Report-Qualität . 14
9.2 Potenzial der LLM-gestützten Aufbereitung für externe CTI-Nutzung 14
9.3 Untersuchung des Einflusses von Report-Aggregation auf Detectionsergebnisse (Echo-Chamber-Effekt?) 14

10 Zusammenfassung und Fazit **15**

Bibliography **16**

Abkürzungsverzeichnis

DNN	Deep Neural Network
DoS	Denial of Service
IPFS	InterPlanetary File System
P2P	Peer-to-Peer
CID	Content Identifier
MADDR	Multiaddress
CTI	Cyber Threat Intelligence

1 Einleitung

1.1 Motivation und Problemstellung

Obwohl die node-basierten Detektionsmechanismen der betrachteten Ladeinfrastruktur bereits eine beachtliche Erkennungsleistung aufweisen, besteht das Ziel, die Spezifität (True-Negative-Rate) sowie die Robustheit des Gesamtsystems weiter zu steigern. Lokale Anomalieerkennungsverfahren stoßen systembedingt an Grenzen, wenn netzwerkweite Veränderungen oder subtile, koordinierte Manipulationsversuche vorliegen, die auf Ebene einer einzelnen Wallbox nicht als bösartig identifiziert werden können.

Quelle evtl. mit meiner Bachelorarbeit arbeiten

Quelle schwierige erkennung wenn netzwerkweite Veränderung und nicht am Knoten selbst

Die Motivation dieser Arbeit liegt daher in der Entwicklung einer Methodik, die es einzelnen Ladepunkten ermöglicht, Kontextinformationen benachbarter Knoten in den Entscheidungsprozess einzubeziehen. Es wird vermutet, dass durch diesen kollaborativen Ansatz räumliche und zeitliche Korrelationen innerhalb des Netzwerks besser erfasst werden können, die über die isolierte Betrachtung eines einzelnen Knotens hinausgehen. Durch die Integration dieser Kontextdaten wird erhoft eine präzisere Differenzierung zwischen globalen Schwankungen und lokalen Sicherheitsvorfällen zu ermöglichen. Es wird erwartet, dass dieser erweiterte Kontextbezug zu einer Reduktion von Fehlalarmen (False Positives) sowie einer verbesserten Erkennungsrate tatsächlicher Bedrohungen (True Positives) beiträgt. Inwiefern diese Annahmen empirisch belastbar sind, bleibt jedoch offen und soll in einer weiterführenden Arbeit durch die Evaluation anhand eines unabhängigen Datensatzes systematisch untersucht werden.

1.2 Zielsetzung der Arbeit

Um die dargelegte Problemstellung zu adressieren, liegt der Fokus dieser Arbeit auf der Konzeption und Implementierung einer robusten Infrastruktur für die Anomalieerkennung innerhalb der Ladeinfrastruktur. Übergeordnetes Ziel ist die Schaffung einer stabilen Betriebsumgebung, die einen zuverlässigen, kontextbasierten Datenaustausch zwischen den einzelnen Knoten gewährleistet.

Ein wesentlicher Aspekt hierbei ist die Realisierung einer konsistenten und effizienten Aggregation dezentraler Informationen, um die Detektionsgüte der beteiligten Entitäten signifikant zu steigern. Nur durch eine performante Umgebung, welche den reibungslosen Austausch von Kontextinformationen sicherstellt, kann die in Kapitel 3 (Systemarchitektur und Detection Framework) detaillierte Anomalieerkennung erfolgreich implementiert und langfristig wartbar betrieben werden. Die Entwicklung dieser stabilen Kommunikations- und Verarbeitungsplattform bildet somit den zentralen Kernbestandteil der vorliegenden Arbeit.

1.3 Aufbau der Arbeit

Zunächst wird die Systemarchitektur im zur Verfügung stehenden Peer-to-Peer-Netzwerk beschrieben sowie die implementierten Detektionen und die Datenakquise über Prometheus empirisch erläutert und differenziert.

Darauf folgend wird die Konzeption des Threat Reporters vorgestellt, welcher die Detektionsergebnisse in einem standardisierten Format aggregiert und über definierte Schnittstellen zwischen den Knoten überträgt.

Anschließend werden die theoretischen Grundlagen der Informationsfusion präsentiert.

Darauf folgend wird die Methodik der gewichteten Aggregation mittels Utility Theory beschrieben.

Anschließend wird die erweiterte Architektur und umsetzung der Vorgestellten Methodik beschrieben. Die Daraus generierten Threat Reports werden präsentiert und hinsichtlich ihrer Qualität und Nützlichkeit für die interne Nutzung der Knoten bewertet.

Die anschließende Diskussion der Ergebnisse führt zur Identifikation einer Forschungslücke, welche in zukünftigen Arbeiten weiter untersucht werden sollte.

Vielleicht

TODO: Sollte hier wissenschaftlich begründet werden, warum die Wahl auf eine Kombination aus Deep Sets und Attention-Mechanismen gefallen ist?

TODO: Die Formel der Utility Theory wurde nicht originär für Gewichtungsfunktionen entwickelt. Wie problematisch ist das? Sollte dies in der Diskussion thematisiert oder direkt eine alternative Methode verwendet werden?

TODO: Fokus darauf legen wie die zuvor beschriebenen Methoden in die Architektur einbepflegt wurden

Welche Forschungslück

TODO: Mögliche Forschungslück

2 Related Work

3 Systemarchitektur und Detection Framework

3.1 Systemüberblick und verteilte Kommunikation

Das ReSiLENT-System gliedert sich in zwei logische Domänen: die **Charging Station** mit dem eingebetteten Detection-Client sowie das **Cloud Dashboard** zur zentralen Visualisierung und Auswertung. Beide Domänen sind über ein privates Peer-to-Peer-Netzwerk auf Basis des *Inter-Planetary File System* (IPFS) lose gekoppelt. Anstelle direkter IP-zu-IP-Verbindungen erfolgt der Datenaustausch über inhaltsadressierte Bezeichner (*Content Identifier*, CIDs).

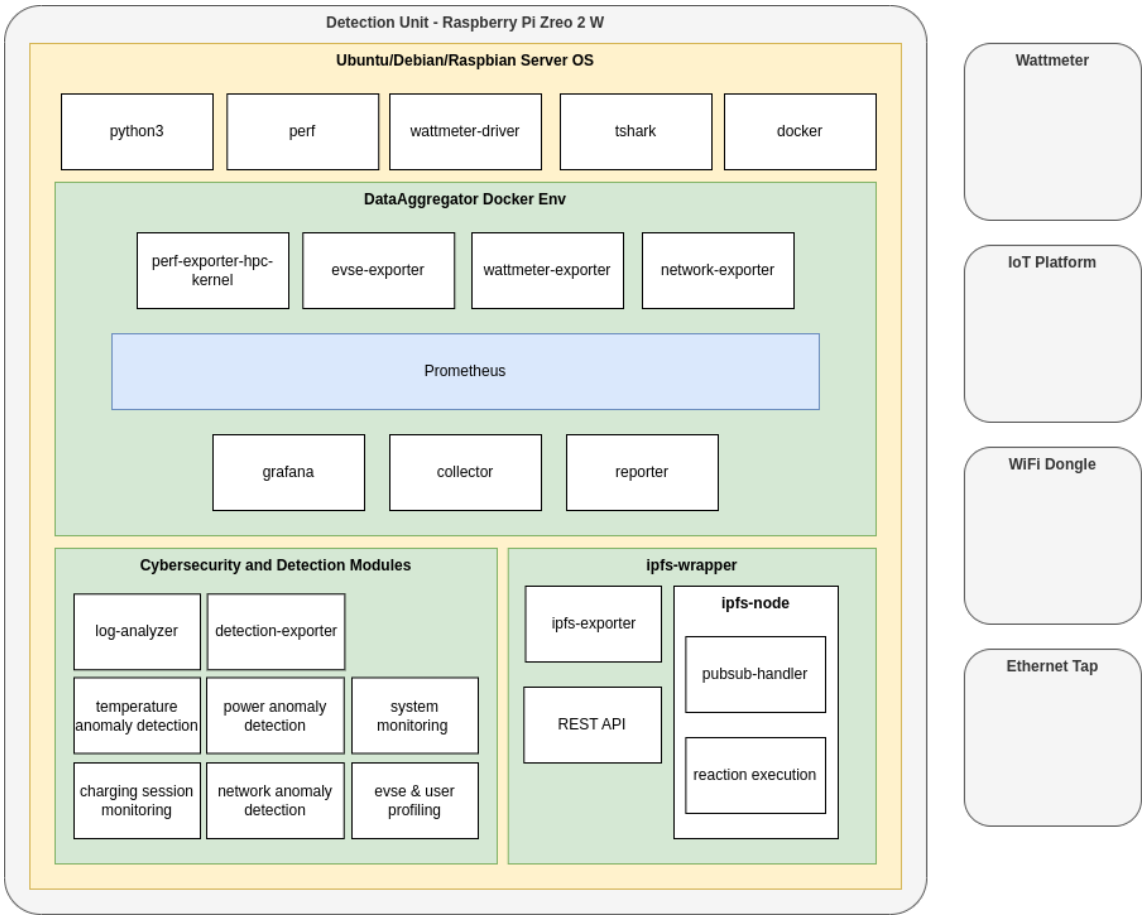

Figure 1: Gesamtarchitektur des ReSiLENT-Systems mit Charging Station und Cloud Dashboard

Abbildung 1 zeigt die Gesamtarchitektur des Systems mit Fokus auf die in jeder Wallbox eingebettete Detection Unit. Als zentrales Laufzeitmodul fungiert der *DataAggregator*, der die erfassten Sensordaten der Wallbox über Prometheus bereitstellt und sowohl den Cybersecurity- und Detection-Modulen als auch Werkzeugen zur Datenaufbereitung zugänglich macht.

Die Architektur ist auf kollaborative Angriffserkennung ausgelegt: Über den *ipfs-wrapper* und dessen **Publish-Subscribe-Mechanismus** (detailliert in Abbildung 2) teilen Ladesäulen Kontextinformationen mit allen Netzwerkteilnehmern und können somit die situative Wahrnehmung über die gesamte Ladeinfrastruktur hinweg verbessern.

3.1.1 Privates IPFS-Netzwerk und Peer-to-Peer-Datenaustausch

Für die verteilte Kommunikation zwischen den Detection Units und dem Cloud Dashboard wird ein **privates IPFS-Netzwerk** eingesetzt. Im Gegensatz zum öffentlichen IPFS-Netz wird der Zugang durch einen gemeinsamen *Swarm Key* beschränkt, sodass ausschließlich autorisierte Knoten dem Netzwerk beitreten können. Die Netzwerktopologie ist in Abbildung 2 dargestellt.

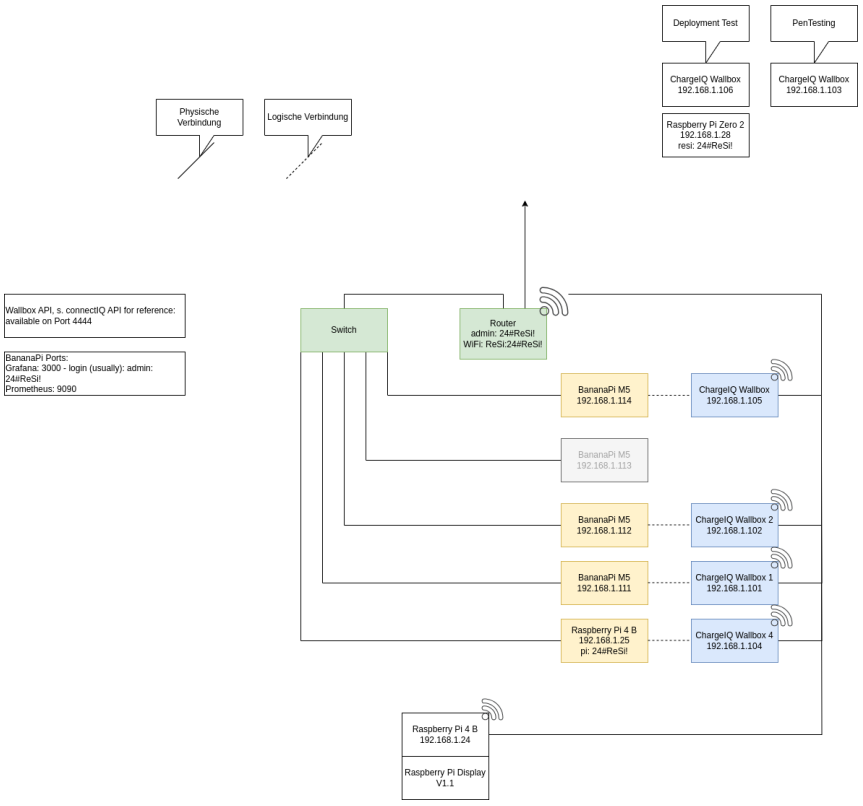

Figure 2: Topologie des privaten IPFS-Netzwerks mit Bootstrap-Node und Client-Peers

Der Netzbeitritt erfolgt über einen dedizierten **Bootstrap-Node**, der auf dem Server des Cloud Dashboards betrieben wird. Neue Peers melden sich beim Bootstrap-Node an, erhalten die Multiaddresses (*MADDR*) der bekannten Peers und kommunizieren anschließend direkt miteinander, ohne den Bootstrap-Node als Relay zu verwenden. Jede Detection Unit betreibt einen lokalen **IPFS-Peer-Daemon**, der über den `ipfs-wrapper` – wie in Abbildung 3 dargestellt – in die Systemarchitektur eingebunden ist.

Für die Benachrichtigung über neue Daten wird der **Publish-Subscribe-Mechanismus** von IPFS genutzt: Sobald eine Detection Unit neue Messdaten veröffentlicht, sendet sie die zugehörige CID zusammen mit der eigenen MADDR über einen gemeinsam abonnierten Kanal an alle Teilnehmer. Die Empfänger rufen die Datei daraufhin direkt beim Ursprungs-Peer ab. Da eine CID dem kryptografischen Hash des jeweiligen Inhalts entspricht, ist die Datenintegrität implizit gewährleistet, ohne dass zusätzliche Signaturmechanismen erforderlich sind.

3.1.2 End-to-End-Datenfluss

Der vollständige Datenfluss vom Sensor bis zur Visualisierung lässt sich in drei Phasen unterteilen: Datenerhebung und Aggregation auf der Charging Station, Transport über das IPFS-

Netz sowie Persistierung und Darstellung im Cloud Dashboard. Das Sequenzdiagramm in Abbildung 4 sowie der Datenfluss in Abbildung 3 illustrieren diesen Ablauf.

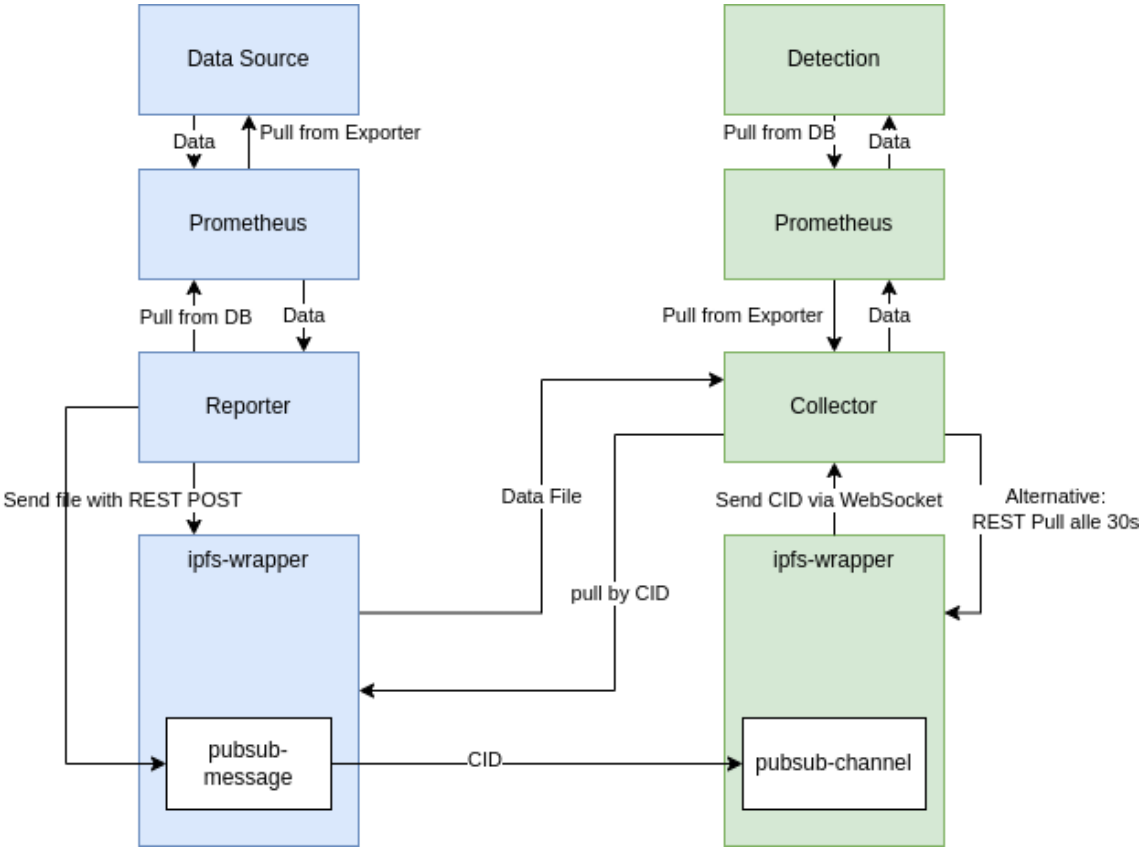

Figure 3: Datenfluss zwischen Charging Station (blau) und Cloud Dashboard (grün) über IPFS

Datenerhebung (Charging Station)

Der *Aggregator* innerhalb des Detection-Clients sammelt die Messdaten. Prometheus scraped alle Exporter in konfigurierbaren Intervallen. Der *Reporter* liest die aggregierten Daten aus der Prometheus-Datenbank und übermittelt sie an den `ipfs-wrapper`.

Transport (IPFS-Netzwerk)

Der `ipfs-wrapper` nimmt die Datei entgegen, publiziert sie im lokalen IPFS-Node und erhält eine CID zurück. Anschließend wird die CID zusammen mit der eigenen MADDR über den konfigurierten **Publish-Subscribe-Mechanismus** im privaten IPFS-Netz verbreitet. Die eigentlichen Messdaten werden dabei nicht aktiv gepusht, lediglich der Zeiger (CID) wird distribuiert.

Persistierung und Visualisierung (Cloud Dashboard)

Auf der Serverseite empfängt der *Publish-Subscribe-Event-Listener* des `ipfs-wrapper` die CID und MADDR und leitet diese per **WebSocket** an den Collector weiter. Der Collector fordert daraufhin die vollständige Datei über den lokalen IPFS-Peer an, der sie in Chunks vom Ursprungs-Peer abruft. Der *File Extractor* verarbeitet die Rohdaten und persistiert die Messwerte in **InfluxDB**. Grafana greift auf InfluxDB zu und stellt die Zeitreihendaten im Dashboard dar (vgl. Abbildung 5).

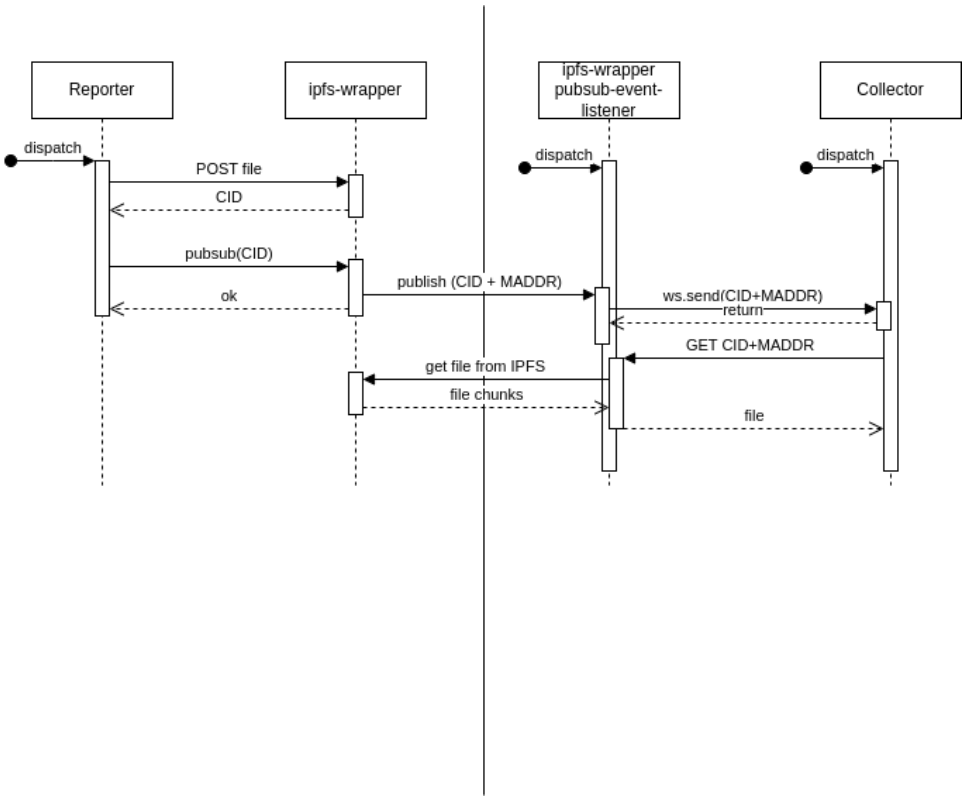

Figure 4: Sequenzdiagramm des IPFS-basierten Datenaustausches

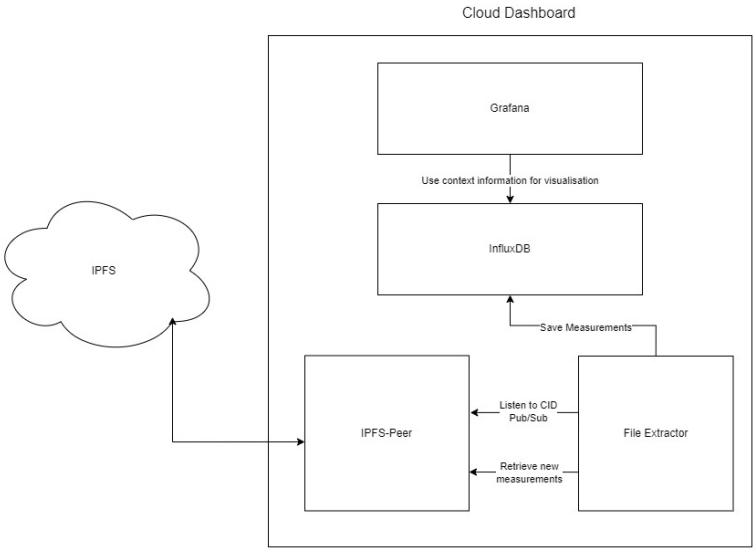

Figure 5: Komponenten des Cloud Dashboards: IPFS-Peer, File Extractor, InfluxDB und Grafana

Warum genau habe ich das jz beschrieben noch ein abschließender Satz

3.2 Physische Testumgebung

3.3 Detection Units der Ladeinfrastruktur

3.3.1 System- und Leistungsanomaliedetektion (pi_anomaly_detection)

3.3.2 Physikalische Signal- und Temperaturüberwachung (detection_power_temperature)

3.3.3 KI-basierte Angriffserkennung im Netzwerk (ids_power_ai_detection)

3.3.4 Hardware-Ereignisüberwachung (detection_hardwareevents)

4 Konzeption des Threat Reporters

4.1 Standardisierung durch den Threat Report (CSV/STIX)

4.2 Zeitfenster-Analyse und Datenaggregation (60s/30s Intervalle)

4.3 Schnittstellendesign für den Datentransfer zwischen Nodes

5 Theoretische Grundlagen der Informationsfusion

5.1 Vergleich von Aggregationsmethoden

5.1.1 Dempster-Shafer-Evidenztheorie

5.1.2 Fuzzy-basierte Fusion

5.1.3 Bayes-basierte Konsensmodelle

5.1.4 Gewichtetes Voting

5.2 State-of-the-Art: Deep Sets und Attention Mechanismen

6 Methodik: Gewichtete Aggregation mittels Utility Theory

6.1 Anforderungen an die Gewichtungsfunktion

6.2 Mathematische Modellierung

6.2.1 Die Gewichtungsformel: $w(n) = BASE_WEIGHT + (MAX_WEIGHT - BASE_WEIGHT) \times (1 - \exp(-K \cdot n))$

NIcht in die überschrift

6.2.2 Parameteranalyse: Monotonie und Diminishing Returns

6.2.3 Abgrenzung zur originären Utility Theory

6.3 Implementierung des Attention-basierten Selektionsmodells

7 Erweiterung der Systemarchitektur und Implementierung

7.1 Generierte Threat Reports: Format und Struktur

7.2 Integration von Threat Reporter und Aggregationslogik

7.3 Architektur der Fusionskomponente im P2P-Netzwerk

8 Evaluation

8.1 Qualität der aggregierten Threat Reports

8.2 Nützlichkeit für die interne Nutzung der Knoten

9 Diskussion und Forschungslücken

9.1 Auswirkungen unterschiedlicher Gewichtungsstrategien auf die Report-Qualität

9.2 Potenzial der LLM-gestützten Aufbereitung für externe CTI-Nutzung

9.3 Untersuchung des Einflusses von Report-Aggregation auf Detectionsergebnisse (Echo-Chamber-Effekt?)

10 Zusammenfassung und Fazit

Bibliography

Generative KI-Werkzeuge, die in der Arbeit verwendet wurden.

Kapitel	KI-Tool	Version	Anwendung	Erklärung/Kommentar
1.0–4.2	Perplexity AI	2024	Grammatik- und Rechtschreibkorrektion	Der generierte Output wurde ausschließlich zur Überprüfung und Optimierung der Grammatik, Rechtschreibung und Lesbarkeit verwendet. Sämtliche fachlichen Inhalte, Analysen, Interpretationen und wissenschaftliche Schlussfolgerungen stammen vollständig von mir.
1.0–4.2	Perplexity AI	2024	Verbesserung der Lesbarkeit	Umformulierung von Sätzen zur besseren Verständlichkeit und Fluss des Textes, ohne inhaltliche Veränderungen.

Eidesstattliche Erklärung

Ich versichere hiermit wahrheitsgemäß, die Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt, die wörtlich oder inhaltlich übernommenen Stellen als solche kenntlich gemacht und die Satzung der Ostbayerischen Technischen Hochschule Regensburg zur Sicherung guter wissenschaftlicher Praxis in der jeweils gültigen Fassung beachtet zu haben. Die Arbeit ist weder von mir noch von einer anderen Person an der Ostbayerischen Technischen Hochschule Regensburg oder an einer anderen Hochschule zur Erlangung eines akademischen Grades bereits eingereicht worden.

Regensburg, den 01.04.2026 _____

Yannic Hanel

Todo list

Quelle evtl. mit meiner Bachelorarbeit arbeiten 1

Quelle schwierige erkennung wenn netzwerkweite Veränderung und nicht am Knoten selbst 1

Vielleicht finde ich eine begründung warum ich genaue diese events in den hardware report gepackt habe? 2

TODO: Sollte hier wissenschaftlich begründet werden, warum die Wahl auf eine Kombination aus Deep Sets und Attention-Mechanismen gefallen ist? 2

TODO: Die Formel der Utility Theory wurde nicht originär für Gewichtungsfunktionen entwickelt. Wie problematisch ist das? Sollte dies in der Diskussion thematisiert oder direkt eine alternative Methode verwendet werden? 2

TODO: Fokus darauf legen wie die zuvor beschriebenen Methoden in die Architektur einbepflegt wurden 2

Welche Forschungslücke? 2

TODO: Mögliche Forschungslücken: - Untersuchung der Auswirkungen von unterschiedlichen Gewichtungsstrategien Aggregation auf die Qualität der aggregierten Reports - Erweiterung um die LLM gestützte Aufbereitung der Reports für die externe Nutzung - Untersuchung ob der vorgestellte ablauf, erstellen der reports, aggregieren und nutzung der nachbar reports wirklich zu verbesserten Detectionsergebnissen führt (Echo-Chamber-Effekt?). 2

Warum genau habe ich das jz beschrieben noch ein abschließender Satz 7

NIcht in die überschrift 11